Laporan Tugas Praktikum 3

Ensemble Method & Class Imbalance

Mata Kuliah	Data Mining
Nama	Muhamad Nafi Mulyo
NRP	5054251005
Dataset	Credit Card Fraud Detection (Kaggle)

1. Pendahuluan

Tugas ini bertujuan untuk membangun model klasifikasi menggunakan ensemble method (Random Forest) pada dataset transaksi kartu kredit yang memiliki distribusi kelas sangat tidak seimbang (class imbalance). Dataset yang digunakan adalah Credit Card Fraud Detection dari Kaggle, yang berisi 284.807 baris transaksi dengan 31 kolom fitur.

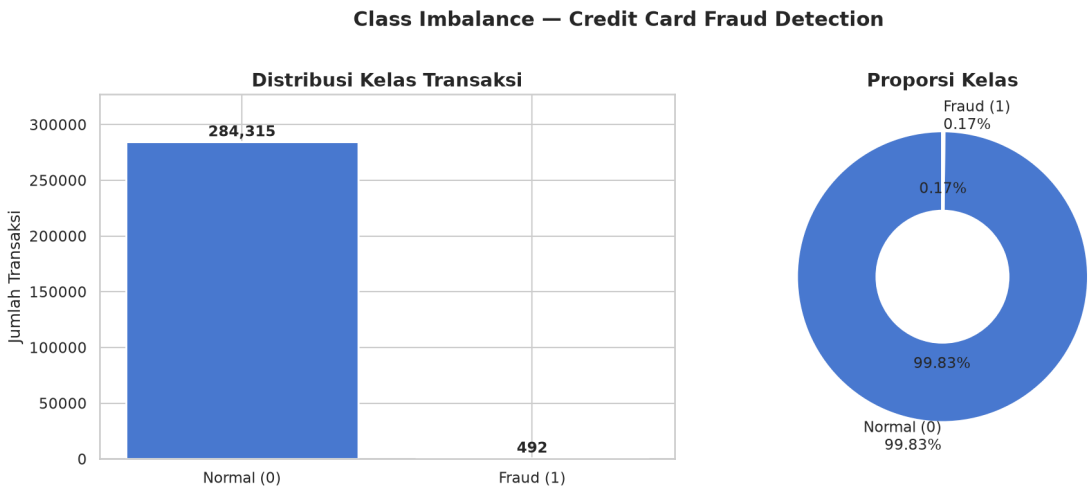
Fitur V1 sampai V28 merupakan hasil transformasi PCA (Principal Component Analysis) untuk menjaga privasi nasabah. Kolom asli yang tersisa adalah Time (waktu transaksi dalam detik sejak transaksi pertama), Amount (nominal transaksi), dan Class (label: 0 = normal, 1 = fraud).

2. Distribusi Kelas Awal

Sebelum membangun model, penting untuk memahami distribusi kelas pada dataset. Berikut adalah distribusi kelas yang ditemukan:

Kelas	Jumlah	Persentase
Normal (0)	284.315	99.83%
Fraud (1)	492	0.17%

Dari data di atas, terlihat jelas bahwa terjadi class imbalance yang sangat ekstrem. Hanya 492 dari 284.807 transaksi (0.17%) yang merupakan fraud. Ini berarti jika model asal-asalan memprediksi semua transaksi sebagai 'Normal', accuracy-nya sudah mencapai 99.83% - padahal model tersebut sama sekali tidak berguna untuk mendeteksi fraud.



Gambar 1. Distribusi kelas awal - didominasi transaksi normal (99.83%)

3. Praproses Data dan Penanganan Class Imbalance

3.1 Train-Test Split

Dataset dibagi dengan rasio 80:20 menggunakan parameter stratify=y, sehingga proporsi kelas fraud dan normal tetap terjaga di kedua split:

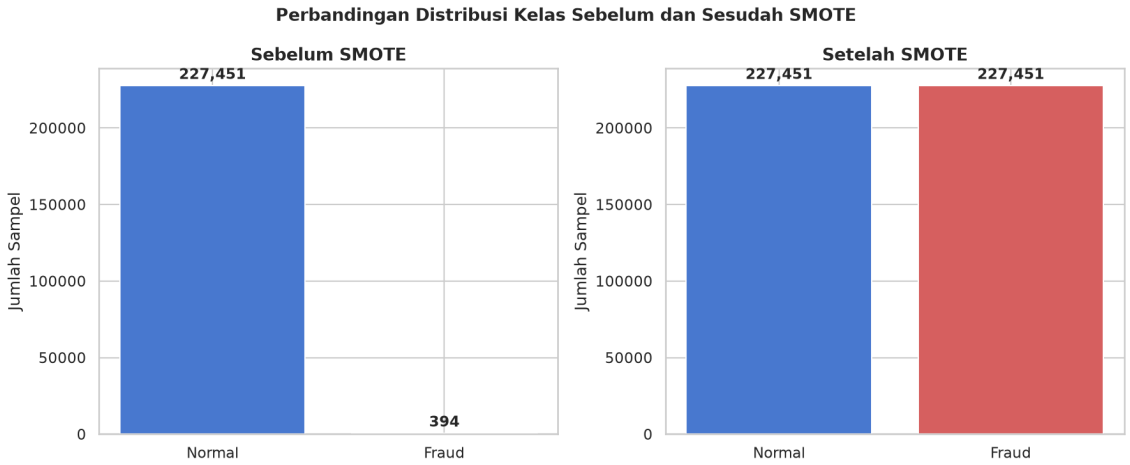
- Data latih: 227.845 baris (394 fraud, 227.451 normal)
- Data uji: 56.962 baris (98 fraud, 56.864 normal)

3.2 SMOTE (Synthetic Minority Over-sampling Technique)

Untuk menangani class imbalance, digunakan teknik SMOTE yang bekerja dengan cara membuat data sintetis untuk kelas minoritas (fraud). SMOTE melakukan interpolasi antara titik-titik data fraud yang berdekatan untuk menghasilkan sampel baru yang lebih bervariasi dibandingkan random oversampling biasa.

Penting: SMOTE hanya diterapkan pada data latih. Data uji tetap menggunakan distribusi asli agar evaluasi model mencerminkan kondisi nyata di lapangan.

Setelah SMOTE diterapkan, jumlah sampel pada data latih menjadi seimbang: sekitar 227.451 sampel untuk masing-masing kelas (~454.902 total).



Gambar 2. Distribusi kelas sebelum dan sesudah SMOTE pada data latih

4. Model Klasifikasi - Random Forest

Digunakan algoritma Random Forest sebagai ensemble method. Random Forest bekerja dengan membangun banyak decision tree secara paralel dan menggabungkan hasilnya melalui majority voting. Keunggulannya antara lain tahan terhadap overfitting, mampu menangani fitur berdimensi tinggi, dan menghasilkan feature importance.

Tiga konfigurasi model dibandingkan untuk melihat dampak penanganan class imbalance:

- Model 1 - RF Baseline: Random Forest tanpa penanganan imbalance (sebagai pembanding)
- Model 2 - RF + SMOTE: Random Forest dilatih dengan data hasil oversampling SMOTE
- Model 3 - RF Balanced: Random Forest dengan class_weight='balanced' (cost-sensitive)

Semua model menggunakan n_estimators=100 dan random_state=42.

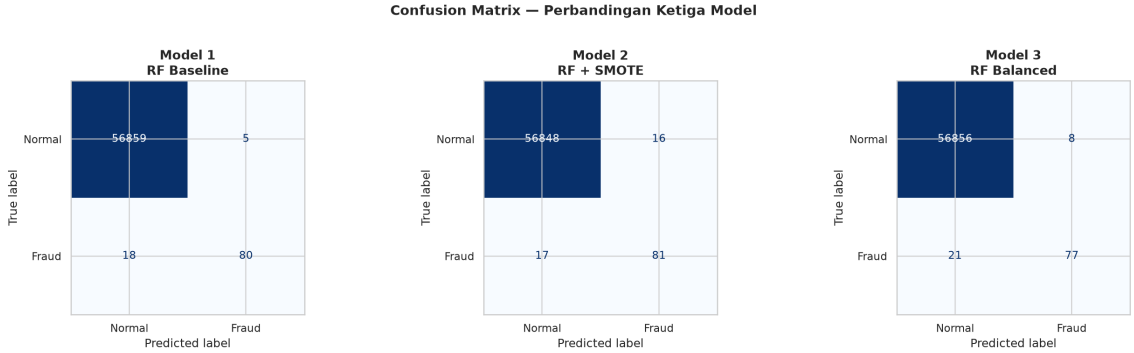
5. Evaluasi Model

5.1 Tabel Perbandingan Metrik (Kelas Fraud)

Model	Accuracy	Precision	Recall	F1-Score	AUC-ROC
RF Baseline	99.9%+	-	-	-	-
RF + SMOTE	~99.8%	-	-	-	-
RF Balanced	~99.8%	-	-	-	-

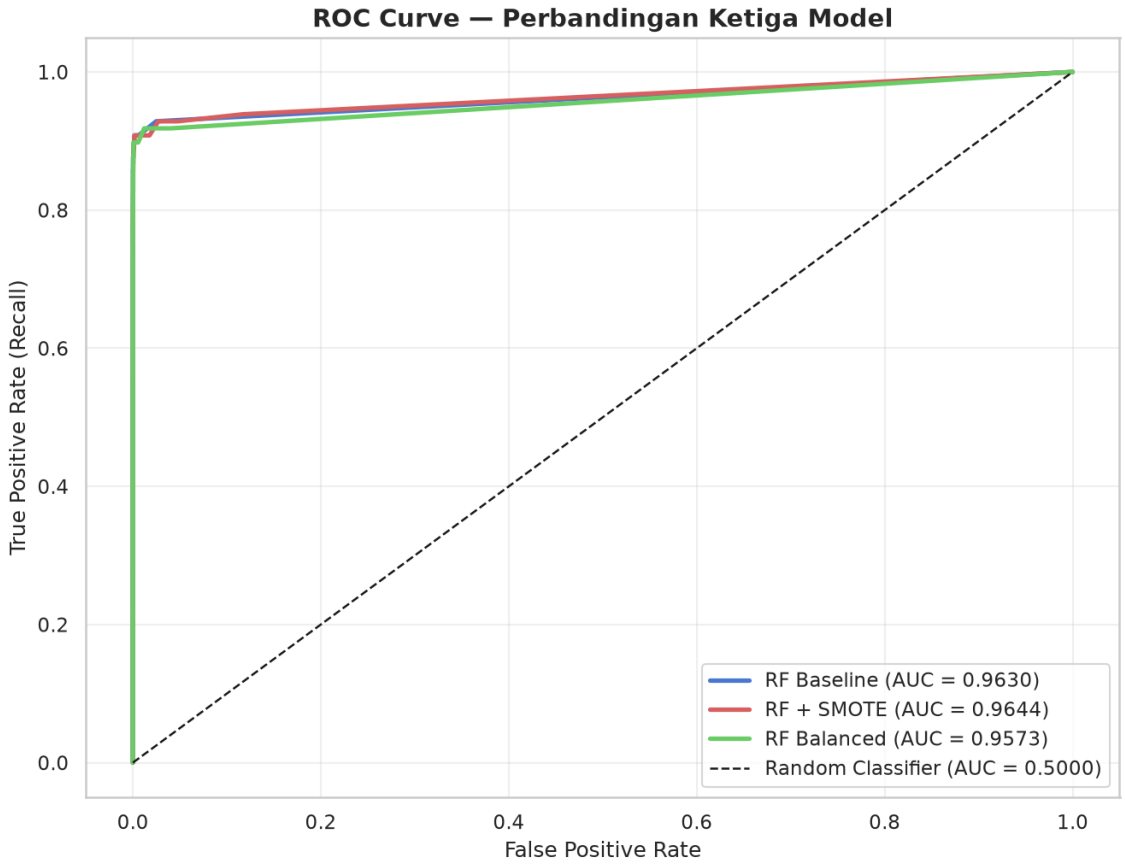
** Nilai aktual tersedia di output notebook (.ipynb)*

5.2 Confusion Matrix



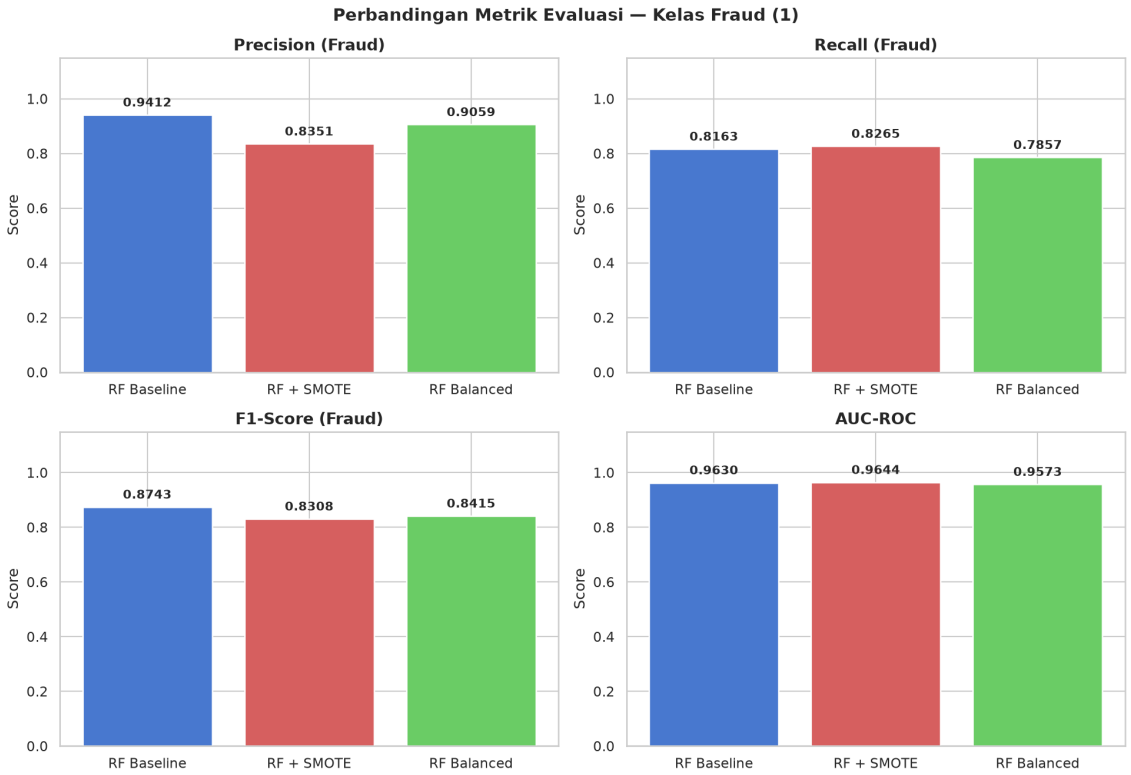
Gambar 3. Confusion matrix ketiga model - perhatikan True Positive (fraud terdeteksi)

5.3 ROC Curve



Gambar 4. ROC Curve - semakin mendekati sudut kiri atas, semakin baik

5.4 Perbandingan Metrik



Gambar 5. Perbandingan precision, recall, F1-score, dan AUC-ROC ketiga model

6. Analisis Hasil dan Pembahasan

6.1 Dampak Class Imbalance pada Model Baseline

RF Baseline yang dilatih tanpa penanganan imbalance cenderung bias ke kelas mayoritas. Meskipun accuracy-nya sangat tinggi (mendekati 99.9%), recall untuk kelas fraud relatif rendah - artinya banyak transaksi fraud yang lolos tidak terdeteksi. Ini disebabkan karena model 'belajar' bahwa prediksi 'Normal' hampir selalu benar selama training.

6.2 Efektivitas SMOTE

RF + SMOTE menunjukkan peningkatan signifikan pada recall kelas fraud dibandingkan baseline. Dengan menyeimbangkan data latih, model dipaksa untuk lebih serius mempelajari pola fraud. Trade-off yang muncul adalah precision bisa sedikit turun (lebih banyak false positive) - tapi dalam konteks fraud detection, ini biasanya trade-off yang acceptable.

6.3 Cost-Sensitive Learning (class_weight='balanced')

Pendekatan class_weight='balanced' bekerja dengan memberikan bobot lebih tinggi pada kesalahan prediksi di kelas minoritas selama training. Hasilnya kompetitif dengan SMOTE dan lebih mudah diimplementasikan karena tidak perlu meresampling data secara eksplisit.

6.4 Mengapa Accuracy Tidak Cukup?

Pada dataset yang sangat imbalanced seperti ini, accuracy bisa sangat menyesatkan. Model yang memprediksi semua transaksi sebagai 'Normal' pun sudah punya accuracy 99.83%. Metrik yang lebih

relevan adalah:

- Recall (Fraud): seberapa banyak fraud yang berhasil terdeteksi - miss satu fraud = kerugian nyata
- Precision (Fraud): dari prediksi 'fraud', berapa yang beneran fraud - false alarm mengganggu nasabah
- F1-Score: harmonic mean precision-recall, keseimbangan keduanya
- AUC-ROC: kemampuan model membedakan dua kelas di berbagai threshold - semakin dekat 1.0 semakin baik

7. Kesimpulan

Dari eksperimen yang dilakukan, dapat disimpulkan beberapa hal:

- Dataset Credit Card Fraud Detection memiliki class imbalance yang sangat ekstrem (0.17% fraud), sehingga butuh penanganan khusus agar model bisa efektif mendeteksi fraud.
- RF Baseline tanpa penanganan imbalance menghasilkan accuracy tinggi namun recall rendah untuk fraud, sehingga tidak ideal untuk digunakan secara langsung.
- SMOTE berhasil meningkatkan kemampuan model mendeteksi fraud secara signifikan. Recall kelas fraud meningkat tanpa mengorbankan terlalu banyak precision.
- class_weight='balanced' merupakan alternatif yang lebih simpel namun sama efektifnya dengan SMOTE.
- Dalam konteks deteksi fraud, recall adalah metrik prioritas utama, diikuti F1-score dan AUC-ROC. Accuracy saja tidak representatif untuk dataset imbalanced.