Tugas Praktikum 5: Sequential Pattern Analysis

Mata Kuliah: Data Mining | **Nama:** Muhamad Nafi Mulyo | **NRP:** 5054251005 | **Dataset:** Online Retail (UCI)

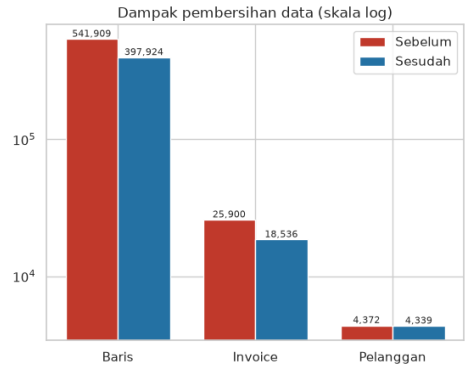
Laporan singkat pola pembelian berurutan pada dataset transaksi ritel online menggunakan algoritma PrefixSpan. Kode lengkap dan seluruh keluaran ada pada notebook pendamping (*5054251005_MuhamadNafiMulyo_Tugas_Sequential_Pattern.ipynb*).

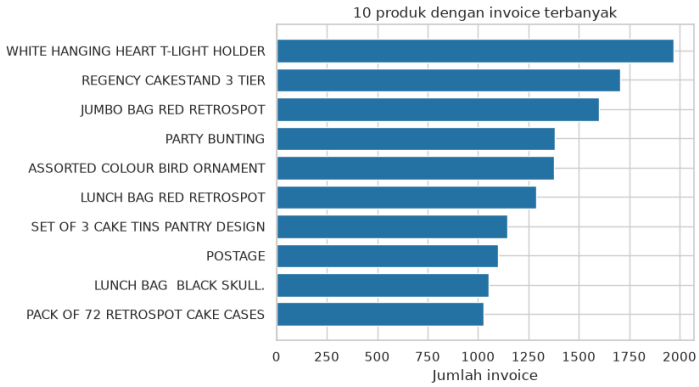
1. Eksplorasi dan Pembersihan Data

Kolom yang dipakai: **CustomerID** (pemilik sequence), **InvoiceDate** (urutan waktu), **InvoiceNo** (pengelompokan itemset), dan **Description** (item). Pembersihan dilakukan sesuai ketentuan, dan nama produk diseragamkan (spasi dibuang, huruf kapital).

Tahap	Baris	Invoice	Pelanggan	Baris dihapus
Data awal	541.909	25.900	4.372	-
Hapus Description kosong	540.455	24.446	4.372	1.454
Hapus invoice dibatalkan (awalan C)	531.167	20.610	4.339	9.288
Hapus Quantity <= 0	530.693	20.136	4.339	474
Hapus CustomerID kosong	397.924	18.536	4.339	132.769

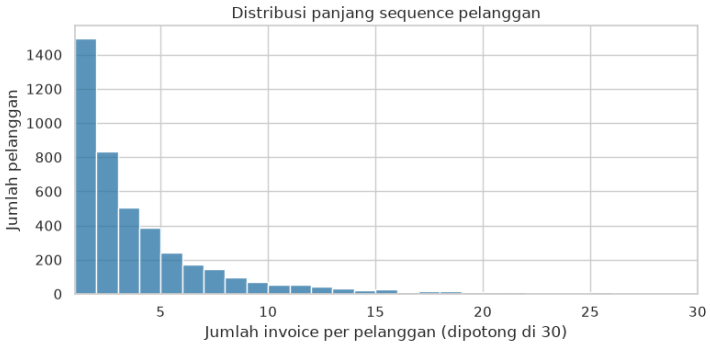
Setelah pembersihan tersisa **397.924 baris**, **18.536 invoice**, **4.339 pelanggan**, dan **3.866 produk unik** (periode 1 Des 2010 - 9 Des 2011). Pengurangan terbesar berasal dari baris tanpa CustomerID, yang harus dibuang karena sequence disusun per pelanggan.





2. Persiapan Sequence

Data diurutkan berdasarkan CustomerID dan InvoiceDate. Produk dalam satu invoice menjadi satu itemset, dan setiap pelanggan menjadi satu sequence (list of list). Terbentuk **4.339 sequence**: rata-rata 4,27 invoice per pelanggan (median 2, maksimum 210) dan 20,9 produk per invoice. Sebanyak **1.494 pelanggan (34,4%) hanya punya satu invoice** sehingga tidak dapat mendukung pola berurutan apa pun.

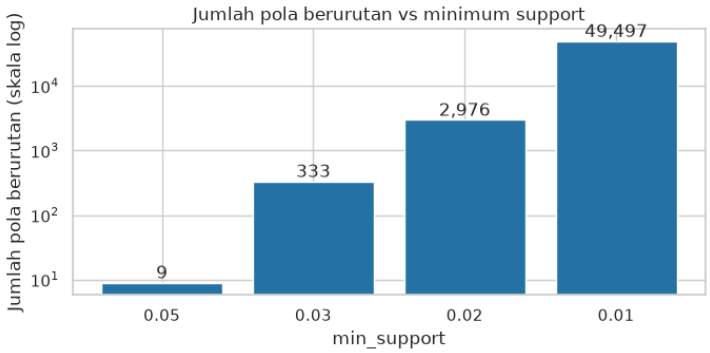


3. Algoritma dan Pemilihan Minimum Support

Algoritma yang dipakai adalah **PrefixSpan** dengan implementasi sendiri (pustaka *prefixspan* di PyPI hanya mendukung item tunggal, bukan itemset). Implementasi memakai S-extension (item masuk invoice berikutnya) dan I-extension (item masuk invoice yang sama) pada projected database, dan hasilnya **sama persis dengan perhitungan brute-force** pada 20 dataset acak. **Support** = proporsi pelanggan yang memuat pola; **confidence** = support(pola) / support(antecedent), dengan antecedent adalah pola tanpa item terakhir. Pola berurutan didefinisikan sebagai pola dengan minimal dua invoice.

min_support	Pelanggan min.	Pola total	Pola berurutan	Waktu	Penilaian
0,05	217	306	9	2 s	Terlalu sedikit, semuanya pembelian ulang produk terlaris
0,03	131	1.259	333	9 s	Agak sempit
0,02	**87**	**5.176**	**2.976**	31 s	**Dipilih**: terbaca, ada pola lintas produk
0,01 (awal)	44	59.121*	49.497*	108 s	Terlalu banyak, didominasi varian produk sama

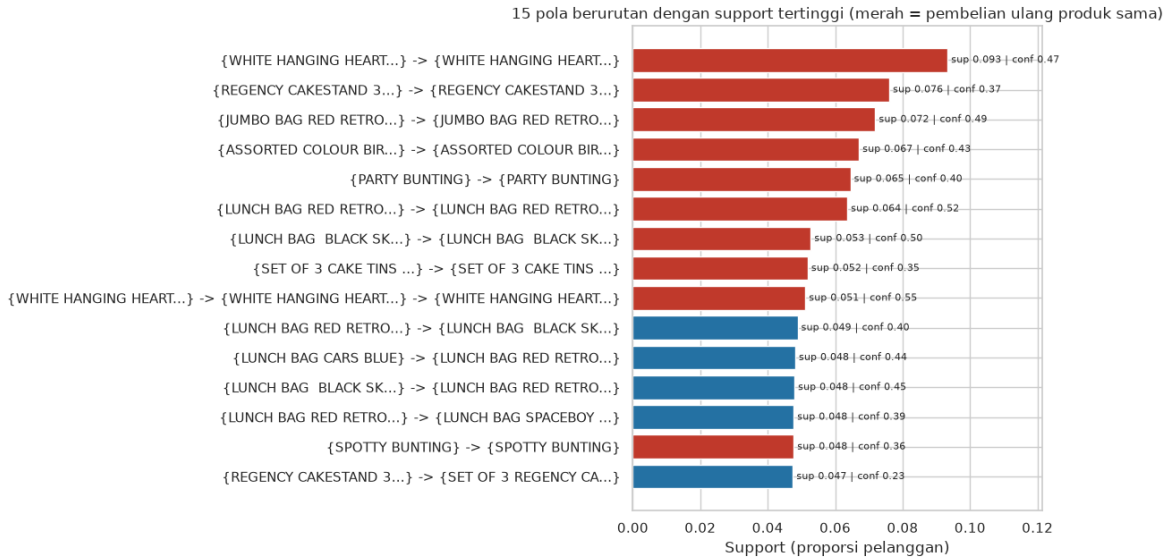
* dibatasi maksimal 3 item per pola (max_len=3), sehingga jumlah sebenarnya lebih besar. Pada min_support 0,02 (tanpa batas panjang) terdapat 2.811 pola lintas produk dan 165 pola pembelian ulang, dengan panjang sampai 4 invoice.



4. Pola Berurutan yang Ditemukan (min_support = 0,02)

Sepuluh pola berurutan dengan support tertinggi (N = 4.339 pelanggan):

#	Pola (A -> B = A dibeli lebih dulu, B di invoice berikutnya)	Pelanggan	Support	Confidence
1	{WHITE HANGING HEART T-LIGHT HOLDER} -> {WHITE HANGING HEART T-LIGHT HOLDER}	405	0,0933	0,473
2	{REGENCY CAKESTAND 3 TIER} -> {REGENCY CAKESTAND 3 TIER}	330	0,0761	0,375
3	{JUMBO BAG RED RETROSPOT} -> {JUMBO BAG RED RETROSPOT}	312	0,0719	0,491
4	{ASSORTED COLOUR BIRD ORNAMENT} -> {ASSORTED COLOUR BIRD ORNAMENT}	291	0,0671	0,429
5	{PARTY BUNTING} -> {PARTY BUNTING}	280	0,0645	0,396
6	{LUNCH BAG RED RETROSPOT} -> {LUNCH BAG RED RETROSPOT}	276	0,0636	0,519
7	{LUNCH BAG BLACK SKULL.} -> {LUNCH BAG BLACK SKULL.}	229	0,0528	0,500
8	{SET OF 3 CAKE TINS PANTRY DESIGN} -> {SET OF 3 CAKE TINS PANTRY DESIGN}	225	0,0519	0,352
9	{WHITE HANGING HEART T-LIGHT HOLDER} -> (sama) -> (sama) [3 invoice]	222	0,0512	0,548
10	{LUNCH BAG RED RETROSPOT} -> {LUNCH BAG BLACK SKULL.}	212	0,0489	0,399



Interpretasi tiga pola terbaik (berdasarkan support)

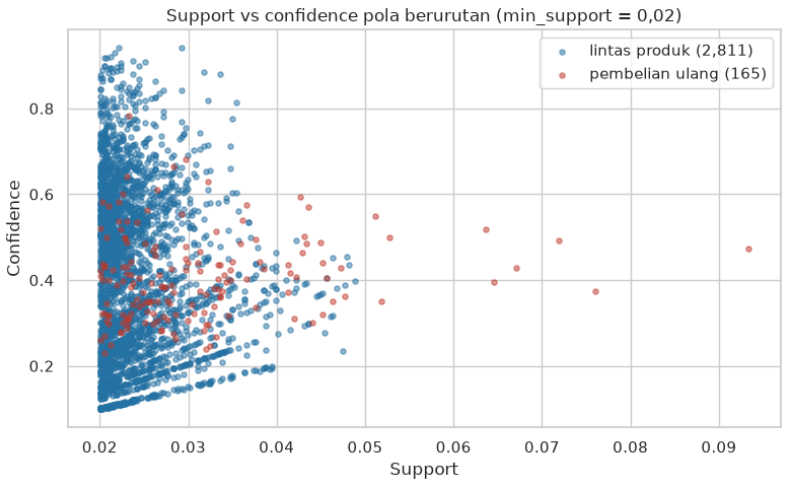
- **WHITE HANGING HEART T-LIGHT HOLDER -> sama** (support 0,0933; confidence 0,473): 405 pelanggan membelinya di dua invoice berbeda. Dari 19,7% pelanggan yang pernah membelinya, 47,3% membelinya lagi. Ini produk andalan toko; stok perlu dijaga dan pembeli barunya cocok diberi pengingat atau paket pembelian ulang.
- **REGENCY CAKESTAND 3 TIER -> sama** (support 0,0761; confidence 0,375): barang tahan lama yang tetap dibeli ulang oleh 37,5% pembelinya, kemungkinan oleh pelanggan grosir yang mengisi ulang stok. Peluang: harga grosir atau diskon pembelian berulang.
- **JUMBO BAG RED RETROSPOT -> sama** (support 0,0719; confidence 0,491): hampir separuh pembelinya membelinya lagi, tertinggi di antara tiga besar. Cocok sebagai produk pancingan dan untuk cross-sell tas seri Retrospot lain.

Ketiganya adalah pembelian ulang produk yang sama (loyalitas/restock). Pola lintas produk dengan support tertinggi:

Pola lintas produk	Pelanggan	Support	Confidence
{LUNCH BAG RED RETROSPOT} -> {LUNCH BAG BLACK SKULL.}	212	0,0489	0,399
{LUNCH BAG CARS BLUE} -> {LUNCH BAG RED RETROSPOT}	209	0,0482	0,436
{LUNCH BAG BLACK SKULL.} -> {LUNCH BAG RED RETROSPOT}	208	0,0479	0,454
{LUNCH BAG RED RETROSPOT} -> {LUNCH BAG SPACEBOY DESIGN}	207	0,0477	0,389
{REGENCY CAKESTAND 3 TIER} -> {SET OF 3 REGENCY CAKE TINS}	206	0,0475	0,234
{JUMBO BAG RED RETROSPOT} -> {JUMBO BAG VINTAGE DOILY}	201	0,0463	0,317

5. Evaluasi Support dan Confidence

Dari 2.976 pola berurutan: rata-rata support 0,024 (median 0,023, maksimum 0,093) dan rata-rata confidence 0,415 (median 0,401, maksimum 0,941). Support rendah karena 34,4% pelanggan hanya punya satu invoice dan pembelian tersebar pada 3.866 produk. Support di atas 0,05 hanya dimiliki 9 pola, semuanya pembelian ulang (titik merah); pola lintas produk berkumpul pada support 0,02 - 0,05.



- **Keluarga LUNCH BAG** adalah pola lintas produk terkuat: pelanggan yang membeli satu desain cenderung membeli desain lain (confidence 0,39 - 0,45), yaitu perilaku melengkapi koleksi.
- **Confidence tertinggi (0,90 - 0,94)** dimiliki pola berisi varian produk satu lini (Gardeners Kneeling Pad, Alarm Clock Bakelike, Regency Tea/Teacup) dengan support hanya 0,02 - 0,03: loyalitas pada satu lini produk.
- **Keterbatasan:** pola tidak dibatasi jarak waktu, varian warna/desain memecah lini produk, dan banyak pelanggan adalah grosir sehingga pembelian ulang bisa berarti restock.

6. Kesimpulan

- Data bersih terdiri dari 397.924 baris, 18.536 invoice, dan 4.339 pelanggan, yang disusun menjadi 4.339 sequence pembelian (median 2 invoice per pelanggan; 34,4% hanya sekali belanja).
- Dengan PrefixSpan dan min_support 0,02 ditemukan 5.176 pola frequent, 2.976 di antaranya berurutan. Nilai awal 0,01 menghasilkan puluhan ribu pola, dan 0,05 hanya 9 pola.
- Pola dengan support tertinggi adalah **pembelian ulang produk terlaris** (WHITE HANGING HEART T-LIGHT HOLDER 9,33%, REGENCY CAKESTAND 3 TIER 7,61%, JUMBO BAG RED RETROSPOT 7,19%) dengan confidence 0,38 - 0,49.
- Pola lintas produk didominasi keluarga *lunch bag* dan pasangan *Regency cakestand* menuju *cake tins*. Rekomendasi: jaga stok produk andalan, tawarkan desain/seri pelengkap setelah pembelian pertama, dan siapkan paket atau harga grosir untuk pembelian berulang.
- Saran lanjutan: tambahkan batas jarak waktu antar invoice, gunakan pola closed/maximal, gabungkan varian produk menjadi kategori, pisahkan pelanggan grosir dan eceran, dan bandingkan dengan GSP.